

IN: Estudio de la relevancia de las variables por su presencia en Random Forest

David Cabezas Berrido

15 de noviembre de 2020

Estudiar la relevancia de las variables en un conjunto de datos es crucial para el preprocesamiento de los mismos, y existen diversas formas de hacer esto. A continuación discutiremos algunas basadas en árboles de decisión:

La primera a considerar sería observar las variables en los **nodos superiores de un Árbol de Decisión**, ya que en cada nodo se separa el conjunto de ejemplos en base al valor de la variable que provoque un mayor descenso de la impureza de **Gini** del conjunto de ejemplos, que es una forma de medir la información que aporta cada variable. Por tanto, las variables que aportan más información sobre el conjunto de datos deberían provocar un mayor descenso en la impureza Gini, por lo que tienen mayor probabilidad de aparecer en los nodos superiores del árbol.

Este método presenta algunos inconvenientes, sobre todo la gran varianza de este modelo, que provoca que el árbol generado y, en consecuencia, los nodos de los niveles superiores, dependan en gran medida de una muestra concreta.

Para solucionar este problema, podemos utilizar bagging para reducir la variabilidad del modelo. Estaríamos entonces ante **Random Forest**. Aquí podríamos generalizar el método anterior: por ejemplo si utilizamos 100 árboles, contaríamos el número de árboles en los que una variable aparece en los 2 ó 3 primeros niveles, pero implementaremos otro criterio: contar el **número de árboles en los que está presente una variable**.

Si hay k variables, en cada nodo se consideran \sqrt{n} variables aleatoriamente y se coloca la que más reduzca la impureza de Gini. Todas las variables tienen las probabilidades de ser consideradas, por lo que las que tienen mayor presencia deberían aportar más información.

Es importante **limitar el número nodos** de los árboles de alguna forma, ya sea añadiendo un coste de complejidad y podando o limitando la profundidad máxima del árbol. Esto es porque si los árboles tienen demasiados nodos, acabarán estando presentes todas las variables o la mayoría de ellas, por lo que este criterio no aportará información.

Aplicamos este criterio al dataset de Mamografías visto en la primera práctica, junto a cada variable mostramos la proporción de árboles en los que está presente.

BI-RADS	0.98
Age	0.7
Shape	0.67
Margin	0.64
Density	0.13

Tabla 1: Proporción de estimadores de RF en los que está presente cada variable

La relevancia de BI-RADS parece muy alta. Le siguen Age, Shape y Margin, que parecen bastante relevantes y están bastante igualadas. Por último está Density, que parece muy poco relevante.

Para comprobar la relevancia de las variables, probamos un KNN con parametros por defecto (5 vecinos) sobre los datos eliminando las variables menos importantes. Medimos la accuracy media de 5 evaluaciones por valización cruzada:

Todas las variables	0.79515
Eliminando Density	0.80364
Eliminando Margin y Density	0.79273

Tabla 2: Accuracy obtenida por KNN con los datos eliminando variables

Como podemos observar, la accuracy ha mejorado al eliminar la variable Density, lo que confirma su poca relevancia. La segunda variable menos relevante según nuestro criterio es Margin, pero su eliminación sí que produce un descenso en la precisión de KNN. Esto no debe extrañarnos, puesto que a pesar de ser la segunda variable con menos presencia, está presente en el 64% de los estimadores.

Con la función `collections.Counter` de *python*, obtenemos la distribución de Density y comprobamos que la mayoría de instancias tienen el valor 3, por lo que su distribución está cerca de ser degenerada, lo que provoca que aporte poca información.

Finalmente, comprobaremos qué variables consideraría relevantes el criterio de consultar los primeros nodos de un árbol de decisión.